Cheatsheet AZ-104 — 09 · VM Scale Sets, autoscale, extensiones y acceso a las VMs

1. VMSS: Flexible vs Uniform

	Flexible (recomendado, default)	**Uniform**
Tipo de VM	VMs **estándar** (Microsoft.Compute/virtualMachines): RBAC, tags, Backup, Site Recovery, API normal	VMs hijas del scale set (API propia); **sin Backup ni ASR**
Instancias máximas	**1 000**	100 con garantía de FD (hasta 3 000 con placement groups múltiples)
Mezclar	Tamaños, **Linux y Windows**, **Spot + normales** en el mismo set; añadir VMs existentes	Todas iguales (misma imagen, tamaño y prioridad)
Zonas y fault domains	Reparte en 1-3 zonas; FD máximo 3 (1 si zonal); **sin update domains**; se puede fijar zona / FD por VM	Zonas 1-3; FD 2, 3 o 5; **5 update domains**
Escalado y salud	Autoscale, scale-in policy, instance protection, instance repair (con **Application Health extension**), upgrade policy Automatic / Rolling / Manual	Lo mismo; además **automatic OS image upgrades** (en Flexible aún en preview) y salud por **LB health probe**; **overprovisioning**
Red	Solo **Load Balancer Standard** / App Gateway; **sin salida a internet por defecto** (NAT Gateway, LB outbound rule o PIP)	Admitía Basic LB (retirado en sept. 2025) y NAT pool
Identidad	Solo **user-assigned** managed identity	System o user-assigned
SLA	99,95 % en FD · **99,99 %** en varias zonas	Igual

- El modo se elige **al crear** y no se puede cambiar. "Mixed VM sizes", "Spot and regular", "attach an existing VM" → Flexible. "Service Fabric / AKS node pools", "automatic OS upgrades", "overprovisioning" → Uniform.
- Instancias nuevas salen de la **imagen** del modelo (Marketplace o **Compute Gallery**); la configuración inicial se hace con **extensiones** (Custom Script), cloud-init o una imagen ya preparada.

2. Autoscale (VMSS y App Service)

Elemento	**Qué es**	**Detalle**
Profile (scale condition)	Hasta **20** por recurso: **Default** (uno), **Recurrence** (días y horas), **Fixed date** (evento concreto)	Orden de evaluación: fixed date → recurrence → default
Capacity	**Minimum / Maximum / Default**	Default = a lo que vuelve si **no puede leer la métrica** (nunca escala por debajo de él en ese caso)
Rule	Hasta **10** por profile; métrica (Percentage CPU, Available Memory Bytes, Network In/Out, Disk, **queue length** de Storage / Service Bus, métricas personalizadas), estadística, **duration** (ventana, p. ej. 10 min), **time grain** (1 min), operador y umbral, acción (**increase / decrease** count, percent o exact), **cooldown** (default **5 min**, por regla)	Una regla de salida y otra de entrada; "> 75 % durante 10 min → +2; < 25 % → −1"
Evaluación	Cada 30-60 s; si varias reglas de salida se disparan, gana la **mayor** capacidad; solo se **reduce** si **todas** las reglas de entrada se cumplen; evita **flapping** (no reduce si eso dispararía una salida)	Cooldown se cuenta por regla desde el último cambio
Predictive autoscale	Escala por adelantado con ML sobre CPU (solo VMSS)	"scale before the daily peak"
Scale-in policy	**Default** (equilibra zonas, luego FD, borra el ID más alto), **NewestVM**, **OldestVM**	"remove the oldest instances first"
Instance protection	Proteger una instancia del scale-in o de todas las operaciones del set	Mantener una VM de diagnóstico
Notificaciones	Email a admins / co-admins / direcciones, **webhook**	—

- Manual: fijar el número de instancias (`az vmss scale --new-capacity 5`). Programado: profile recurrence (horario laboral 10 instancias, noche 2). Métrica externa: cola de Storage → `dividePerInstance`.
- En **App Service** el autoscale es del **plan** (afecta a todas sus apps) y necesita Standard o superior; Premium v2/v3 tiene además **automatic scaling** gestionado (cheatsheet 11).

3. Actualizar el modelo y mantener la salud

Pieza	**Qué hace**
Upgrade policy	**Manual**: cambias el modelo y aplicas tú instancia a instancia (`az vmss update-instances --instance-ids "*"`) · **Automatic**: todas a la vez, sin orden (corte) · **Rolling**: por lotes (% máximo, % no saludables, pausa) y exige **health probe** (Uniform) o **Application Health extension**
Automatic OS image upgrades	Uniform: nueva versión de la imagen de Marketplace / galería → rolling automático; requiere salud configurada
Automatic VM guest patching	Flexible (y VMs sueltas): parches dentro del SO con orquestación de la plataforma
Instance repair	Sustituye instancias no saludables (grace period); necesita Application Health extension o probe
Reimage / Upgrade	Reimage reinstala la instancia desde la imagen; Upgrade aplica el **último modelo** ("Latest model: No" = pendiente)
Terminate notification	Aviso (hasta 15 min) antes de borrar una instancia para vaciarla

4. Extensiones de VM

Extensión	Para qué	Detalles de examen
Custom Script Extension (Microsoft.Compute / CustomScriptExtension; Linux: Microsoft.Azure.Extensions / CustomScript)	Descargar y ejecutar un script **tras** el despliegue (instalar IIS, configurar)	`fileUris` + `commandToExecute`; descarga desde Storage (clave, SAS o **managed identity**) o GitHub; **90 min** máximo; se ejecuta **una vez** (para repetir: cambiar `timestamp` o `forceUpdateTag`); **una sola** por VM; secretos en `protectedSettings`; logs en `C:\WindowsAzure\Logs\Plugins\...` o `/var/log/azure/`; no reiniciar dentro del script; ejecuta como SYSTEM / root
cloud-init (custom data)	Configuración en el **primer arranque** de Linux (paquetes, usuarios, ficheros)	Solo Linux, se pasa con `--custom-data`, corre **antes** que las extensiones; **user data** (ambos SOs) se consulta desde IMDS pero no es secreto
Azure Monitor Agent (AMA)	Recoger métricas y logs del SO para Log Analytics / Monitor con **Data Collection Rules**	Sustituye al Log Analytics agent (MMA, retirado ago. 2024); necesita managed identity; VM insights = AMA + **Dependency agent**
Network Watcher agent	Packet capture, connection troubleshoot, Connection monitor	Se instala sola al usar esas herramientas
VMAccess	Resetear contraseña, usuario, claves SSH, RDP	Help → Reset password; `az vm user update`
AADLoginForWindows / AADSSHLoginForLinux	Iniciar sesión con **Entra ID**	Más roles Virtual Machine Administrator Login / User Login; MFA por Conditional Access
Microsoft Antimalware	Antivirus en Windows	Defender for Endpoint vía Defender for Cloud es lo moderno
Key Vault VM extension	Traer certificados de Key Vault y renovarlos	—
DSC / Machine Configuration	Estado deseado (DSC en retirada → **Azure Machine Configuration** con Azure Policy)	"audit a setting inside the VM" → guest configuration policy
Azure Disk Encryption	BitLocker / dm-crypt (cheatsheet 08)	—

- Estados: Provisioning succeeded / **transitioning** (en marcha) / **failed** (ver logs; causa nº 1: error del script o URL inaccesible por NSG / firewall de storage). Las extensiones necesitan el **VM Agent** (viene en las imágenes de Marketplace). En VMSS, mejor desplegar la extensión con CLI / PowerShell / plantilla y managed identity: la SAS del portal caduca y rompe el scale-out.

5. Automatización alrededor de las VMs

Herramienta	Para qué	Señal
Run command	Script puntual sin red ni RDP (`az vm run-command invoke`)	"cannot RDP, fix the firewall"
Azure Automation	Runbooks PowerShell / Python con **schedules**, webhooks, **Hybrid Runbook Worker** para on-prem; State Configuration (en retirada)	"run a script every night", "stop VMs at 19:00"
Start/Stop VMs v2	Solución basada en Functions para arrancar / parar por horario o CPU	"start VMs at 8:00 and stop at 19:00"
Auto-shutdown	Solo apagar a una hora, con notificación	"shut down dev VMs daily"
Azure Update Manager	Parches, schedules de mantenimiento, patch orchestration	"install updates on a schedule"
Azure Policy (guest configuration)	Auditar / aplicar configuración dentro del SO	"audit VMs where a service is disabled"
VM Image Builder	Construir imágenes personalizadas en pipeline	"build images automatically"

6. Acceder a las VMs

Vía	Cómo	Detalle
RDP 3389 / SSH 22 por IP pública	NSG con regla desde IPs concretas; **Just-in-time** (Defender for Cloud) abre el puerto solo a petición y por tiempo	Evitar "Any" en origen
Azure Bastion	RDP / SSH **en el navegador** (puerto 443) sin IP pública en la VM; subnet **AzureBastionSubnet /26 o mayor**, IP pública **Standard estática**; llega a VMs de **VNets emparejadas**	SKUs: **Developer** (gratis, sin subnet, limitado) · **Basic** (2 instancias) · **Standard** (host scaling 2-50, **cliente nativo** mstsc / ssh, **transferencia de ficheros**, **shareable links**, puertos personalizados, conexión por IP) · **Premium** (+ **session recording**, private-only)
Serial console	Consola sin red	Boot diagnostics activo
Entra ID login	Extensión + rol; MFA con Conditional Access	"no local admin accounts", "require MFA to RDP"
VPN / ExpressRoute	RDP a la IP **privada** desde on-prem	Cheatsheet 13
Run command / VMAccess	Reparar sin entrar	—

7. Comandos que caen

Tarea	PowerShell	Azure CLI
Crear VMSS	`New-AzVmss -ResourceGroupName RG1 -VMScaleSetName vmss1 -Location westeurope -OrchestrationMode Flexible -ImageName Ubuntu2204 -InstanceCount 2 -Zone 1,2,3 -UpgradePolicyMode Rolling`	`az vmss create -g RG1 -n vmss1 --image Ubuntu2204 --orchestration-mode Flexible --instance-count 2 --zones 1 2 3 --vm-sku Standard_D2s_v5 --upgrade-policy-mode Rolling --lb lb1 --admin-username azureuser --generate-ssh-keys`
Escalar a mano	`Update-AzVmss -ResourceGroupName RG1 -VMScaleSetName vmss1 -SkuCapacity 5`	`az vmss scale -g RG1 -n vmss1 --new-capacity 5`
Autoscale	`$r = New-AzAutoscaleScaleRuleObject -MetricTriggerMetricName "Percentage CPU" -MetricTriggerMetricResourceUri <vmss id> -MetricTriggerOperator GreaterThan -MetricTriggerStatistic Average -MetricTriggerThreshold 75 -MetricTriggerTimeAggregation Average -MetricTriggerTimeGrain (New-TimeSpan -Minutes 1) -MetricTriggerTimeWindow (New-TimeSpan -Minutes 10) -ScaleActionDirection Increase -ScaleActionType ChangeCount -ScaleActionValue 1 -ScaleActionCooldown (New-TimeSpan -Minutes 5) → $p = New-AzAutoscaleProfileObject -Name p1 -CapacityDefault 2 -CapacityMinimum 2 -CapacityMaximum 10 -Rule $r → New-AzAutoscaleSetting -Name as1 -ResourceGroupName RG1 -Location westeurope -TargetResourceId <vmss id> -Profile $p`	`az monitor autoscale create -g RG1 --resource vmss1 --resource-type Microsoft.Compute/virtualMachineScaleSets --min-count 2 --max-count 10 --count 2 · az monitor autoscale rule create -g RG1 --autoscale-name vmss1 --condition "Percentage CPU > 75 avg 10m" --scale out 2 · --condition "Percentage CPU < 25 avg 10m" --scale in 1`
Aplicar modelo	`Update-AzVmssInstance -ResourceGroupName RG1 -VMScaleSetName vmss1 -InstanceId "*"`	`az vmss update-instances -g RG1 -n vmss1 --instance-ids "*" · az vmss update -g RG1 -n vmss1 --set upgradePolicy.mode=Rolling`
Custom Script	`Set-AzVMCustomScriptExtension -ResourceGroupName RG1 -VMName vm1 -Location westeurope -FileUri https://.../install.ps1 -Run install.ps1 -Name cse · VMSS: Add-AzVmssExtension`	`az vm extension set -g RG1 --vm-name vm1 --name CustomScriptExtension --publisher Microsoft.Compute --settings '{"fileUris":["https://.../install.ps1"],"commandToExecute":"powershell -ExecutionPolicy Unrestricted -File install.ps1"}' · Linux: --name CustomScript --publisher Microsoft.Azure.Extensions · VMSS: az vmss extension set`
Ver extensiones	`Get-AzVMExtension -ResourceGroupName RG1 -VMName vm1`	`az vm extension list -g RG1 --vm-name vm1 -o table · az vm get-instance-view`
Entra login	`Set-AzVMExtension -Publisher Microsoft.Azure.ActiveDirectory -ExtensionType AADLoginForWindows -Name AADLogin ... + New-AzRoleAssignment -RoleDefinitionName "Virtual Machine Administrator Login"`	`az vm extension set --publisher Microsoft.Azure.ActiveDirectory --name AADSSHLoginForLinux ... + az role assignment create --role "Virtual Machine User Login" --assignee ... --scope <vm id>`
Bastion	`New-AzBastion -ResourceGroupName RG1 -Name bas1 -PublicIpAddressRgName RG1 -PublicIpAddressName pip-bas -VirtualNetworkRgName RG1 -VirtualNetworkName vnet1 -Sku Standard`	`az network bastion create -g RG1 -n bas1 --public-ip-address pip-bas --vnet-name vnet1 --sku Standard -l westeurope · cliente nativo: az network bastion rdp --name bas1 -g RG1 --target-resource-id <vm id>`
Run command	`Invoke-AzVMRunCommand -ResourceGroupName RG1 -VMName vm1 -CommandId RunPowerShellScript -ScriptString "Set-NetFirewallRule ..."`	`az vm run-command invoke -g RG1 -n vm1 --command-id RunPowerShellScript --scripts "Get-Service"`

8. Árbol de decisión

```
¿Qué pide el enunciado?
├─ Escalar VMs iguales automáticamente ..... VMSS (Flexible) + autoscale
├─ Mezclar tamaños, Spot y normales, o añadir VMs existentes ..... VMSS Flexible
├─ Automatic OS image upgrades u overprovisioning ..... VMSS Uniform
├─ Escalar por horario (oficina / noche) ..... Autoscale profile Recurrence
├─ Escalar por cola de mensajes ..... Regla con métrica de Storage Queue / Service Bus
├─ Evitar que una instancia concreta se borre ..... Instance protection
├─ Actualizar sin corte ..... Upgrade policy Rolling + Application Health extension
├─ Instalar software tras desplegar ..... Custom Script Extension (o cloud-init en Linux)
├─ Volver a ejecutar el script ..... Cambiar timestamp / forceUpdateTag
├─ Recoger logs del SO en Log Analytics ..... Azure Monitor Agent + Data Collection Rule
├─ Resetear la contraseña del admin ..... VMAccess (Help → Reset password)
├─ RDP sin IP pública ..... Azure Bastion (cliente nativo → Standard)
├─ Grabar sesiones RDP ..... Bastion Premium
├─ Entrar con Entra ID y MFA ..... Extensión AADLogin + rol VM Admin/User Login + CA
├─ Apagar VMs de desarrollo cada noche ..... Auto-shutdown (o Start/Stop v2 si hay que arrancar)
└─ Reparar la VM sin red ..... Run command / Serial console
```

9. Señales → respuesta

Enunciado	Respuesta
"scale out when CPU exceeds 70 % for 10 minutes"	Regla de autoscale: Percentage CPU > 70, duration 10 min, increase
"instances keep scaling in and out"	Flapping: separar umbrales, subir cooldown
"autoscale uses default count"	No pudo leer la métrica (agente / diagnóstico)
"more instances on weekdays 8-18"	Profile recurrence
"mix Spot and regular instances"	Flexible
"scale set with Basic Load Balancer"	Solo Uniform (y Basic LB está retirado: usar Standard)

Enunciado	Respuesta
"new instances don't have the app installed"	Custom Script Extension en el modelo del VMSS (o imagen de galería)
"script ran once, needs to run again"	timestamp / forceUpdateTag
"extension failed: cannot download the script"	NSG / firewall de storage bloquea; usar managed identity o abrir
"script takes longer than 90 minutes"	Falla: dividir o usar Automation
"configure Linux VM at first boot"	cloud-init (custom data)
"collect Windows event logs to Log Analytics"	AMA + DCR
"Log Analytics agent", "MMA"	Retirado: migrar a AMA
"RDP to VMs without public IPs from the portal"	Bastion
"Bastion subnet /27 fails"	AzureBastionSubnet mínimo **/26**
"connect with mstsc through Bastion"	SKU Standard (cliente nativo)
"copy files through Bastion"	Standard (file transfer)
"VM in a peered VNet through Bastion"	Soportado: un Bastion en el hub
"update the scale set model but instances unchanged"	Upgrade policy Manual: `update-instances`
"prevent the old instance from being removed"	Instance protection

10. Errores a evitar

1. Elegir Uniform cuando piden mezclar tamaños o Spot, o Flexible cuando piden automatic OS upgrades.
2. Poner una sola regla de autoscale (sin la de scale-in) o umbrales que se solapan (flapping).
3. Esperar que una Custom Script Extension se ejecute en cada arranque o dos veces sin cambiar el timestamp.
4. Meter secretos en `settings` en lugar de `protectedSettings`.
5. Desplegar la extensión en un VMSS con una SAS del portal que caduca.
6. Crear AzureBastionSubnet con /27 o con otro nombre, o esperar cliente nativo en Basic.
7. Usar el Log Analytics agent (MMA) en lugar de AMA.
8. Pensar que auto-shutdown también arranca las VMs.